



Universidad
Andrés Bello®

Más allá del píxel: IA y Radiómica en Resonancia Magnética

Pamela Franco Leiva

FECHA



Universidad
Andrés Bello®

Pamela Alejandra Franco Leiva

Correo Electrónico: pamela.franco@unab.cl


PhD, en Ingeniería Eléctrica, PUC

MSc, Física Médica, PUC

Ingeniera Física, USACH

BSc, Física Aplicada, USACH

Profesora Investigadora en el Departamento de Ingeniería Eléctrica e Ingeniería en Automatización y Robótica – Centro de Transformación Energética



Universidad
Andrés Bello®

¿Cuáles fueron los hallazgos?






Universidad
Andrés Bello®


¿Cuáles fueron los hallazgos?



Universidad
Andrés Bello®



Puntos a tener presente



Objetivos de la Sesión



Universidad
Andrés Bello®



Comprender

Cómo la IA mejora la sensibilidad mediante la reconstrucción de señales débiles.



Analizar

El flujo radiómico y su capacidad de actuar como una "biopsia virtual".



Integrar

El rol del Tecnólogo Médico en la validación y control de calidad de estas herramientas.

El Compromiso Histórico


En RM siempre hemos tenido que elegir entre Tiempo, Resolución y Señal (SNR).

Si queríamos más sensibilidad (SNR), necesitábamos más tiempo de adquisición. La IA rompe este ciclo.



Limitación: Subjetividad y Ruido

Radiomics = Radio (*radiology*) – omics (*as in genomics or proteomics*)



- La radiómica es la extracción de un gran número de características cuantitativas de imágenes médicas mediante algoritmos de caracterización de datos para descubrir patrones que no son visibles para el ojo humano.
- Un método común es el GLCM (matriz de coocurrencia de niveles de gris), que captura la textura analizando cómo

1. Adquisición y reconstrucción de imágenes sin artefactos
2. Segmentación de imágenes
3. Definición, extracción y cuantificación de características
4. Bases de datos e intercambio de datos
5. Construcción de modelos predictivos y validación de datos prospectivos
6. Análisis de datos *ad hoc* para predicciones en el flujo de trabajo clínico



ARTICLE

Received 25 Nov 2013 | Accepted 29 Apr 2014 | Published 3 Jun 2014 | Updated 7 Aug 2014

DOI: 10.1038/ncomms5006

OPEN

Decoding tumour phenotype by noninvasive imaging using a quantitative radiomics approach

Hugo J.W.L. Aerts^{1,2,3,4,*}, Emmanuel Rios Velazquez^{1,2,*}, Ralph T.H. Leijenaar¹, Chintan Parmar^{1,2}, Patrick Grossmann², Sara Carvalho¹, Johan Bussink⁵, René Monshouwer⁵, Benjamin Haibe-Kains⁶, Derek Rietveld⁷, Frank Hoebers¹, Michelle M. Rietbergen⁸, C. René Leemans⁸, Andre Dekker¹, John Quackenbush⁴, Robert J. Gillies⁹ & Philippe Lambin¹



Human cancers exhibit strong phenotypic differences that can be visualized noninvasively by medical imaging. Radiomics refers to the comprehensive quantification of tumour phenotypes by applying a large number of quantitative image features. Here we present a radiomic analysis of 440 features quantifying tumour image intensity, shape and texture, which are extracted from computed tomography data of 1,019 patients with lung or head-and-neck cancer. We find that a large number of radiomic features have prognostic power in independent data sets of lung and head-and-neck cancer patients, many of which were not identified as significant before. Radiogenomics analysis reveals that a prognostic radiomic signature, capturing intratumour heterogeneity, is associated with underlying gene-expression patterns. These data suggest that radiomics identifies a general prognostic phenotype existing in both lung and head-and-neck cancer. This may have a clinical impact as imaging is routinely used in clinical practice, providing an unprecedented opportunity to improve decision-support in cancer treatment at low cost.



La caracterización molecular de datos genéticos vía biopsia está limitada por:

- Invasividad
- Heterogeneidad espacial y temporal de los tumores



Imagenología

- Representa la masa tumoral completa en los pacientes
- Puede repetirse en el curso de la enfermedad para obtener información temporal
- No invasiva

Rol actual de la imagenología: descripción: existencia del tumor, invasión local, maligno, benigno; evaluación temporal: estable, progresión, remisión

Concepto de Radiómica:

Características de la imagen: densidad, forma, textura


“La radiómica convierte los datos de imagen en un espacio de características explotable de alta dimensión utilizando un gran número de algoritmos de caracterización de datos extraídos automáticamente”

⇒ **Descriptores cuantitativos objetivos y precisos para marcadores pronósticos no invasivos**

Metodología estándar de Radiómica



Universidad
Andrés Bello®



- Es una librería de Python
- **Extraer características** radiómicas de **imágenes médicas**
- Se utiliza principalmente en el área de investigación de imágenes médicas:
 - Cuantificar características de los tejidos
 - Intensidad, forma, textura.
 - Permite correlacionar características basadas en imágenes con criterios de valoración clínicos o biológicos.

- **Amplio conjunto de características:** Incluye estadísticas de primer orden, descriptores de forma y características avanzadas de textura.
- **Entrada flexible:** Soporta múltiples formatos de imagen, incluyendo DICOM y NIfTI, así como máscaras personalizadas para definir ROIs.
- **Preprocesamiento:** Incluye remuestreo, normalización de intensidad y filtrado (por ejemplo, wavelet, laplaciano de Gauss).
- **Personalización:** Las características y parámetros son altamente configurables a través de un archivo de configuración o directamente en Python.
- **Robustez:** Implementa cálculos de características estandarizados y puede generar resultados reproducibles.

1 JAN 2019

ADD A COMMENT

Radiomics Tools (by M Vallieres)

Radiomics MATLAB tools

FREE (W/ OR W/O
COMMERCIAL VERSION)

IMAGE ANALYSIS

RADIOMICS

A package providing **MATLAB** programming tools for radiomics analysis. This package contains 5 folders:

- 'TextureToolbox': MATLAB codes to perform texture analysis from an input 2D or 3D region of interest (ROI). This toolbox is self-contained and can be used on its own outside of the radiomics package. In particular, this texture analysis package


latest

Search docs

[Home](#)
[Installation](#)
[Usage](#)
[Customizing the Extraction](#)
[Pipeline Modules](#)

☐ Radiomic Features

[First Order Features](#)
[Shape Features \(3D\)](#)
[Shape Features \(2D\)](#)
[Gray Level Co-occurrence Matrix \(GLCM\) Features](#)
[Gray Level Size Zone Matrix \(GLSZM\) Features](#)
[Gray Level Run Length Matrix \(GLRLM\) Features](#)
[Neighbouring Gray Tone Difference](#)

Docs » Radiomic Features

 [Edit on GitHub](#)


Radiomic Features

This section contains the definitions of the various features that can be extracted using PyRadiomics. They are subdivided into the following classes:

- [First Order Statistics](#) (19 features)
- [Shape-based \(3D\)](#) (16 features)
- [Shape-based \(2D\)](#) (10 features)
- [Gray Level Co-occurrence Matrix](#) (24 features)
- [Gray Level Run Length Matrix](#) (16 features)
- [Gray Level Size Zone Matrix](#) (16 features)
- [Neighbouring Gray Tone Difference Matrix](#) (5 features)
- [Gray Level Dependence Matrix](#) (14 features)

All feature classes, with the exception of shape can be calculated on either the original image and/or a derived image, obtained by applying one of several filters. The shape descriptors are independent of gray value, and are extracted from the label mask. If enabled, they are calculated separately of enabled input image types, and listed in the result as if calculated on the original image.

Si es de tu interés, visita:
<https://pyradiomics.readthedocs.io/en/latest/>



Características de Primer orden

Energy.

La energía es una medida de la magnitud de los valores de vóxel en una imagen. Un valor mayor implica una mayor suma de los cuadrados de estos valores.

$$energy = \sum_{i=1}^{N_p} (X(i) + c)^2 \quad (2.1)$$

Donde c es un valor opcional, que cambia las intensidades para evitar valores negativos en X . Esto asegura que los vóxeles con los valores de gris más bajos contribuyan menos a la energía, en lugar de los vóxeles con una intensidad de nivel de gris más cercana a 0.

Total Energy

$$TotalEnergy = V_{voxel} \sum_{i=1}^{N_p} (X(i) + c)^2 \quad (2.2)$$

La energía total es el valor de Energy Feature escalado por el volumen del voxel en mm^3 .




Entropy

La entropía especifica la aleatoriedad en los valores de la imagen, midiendo la cantidad promedio de información requerida para codificar los valores de la imagen.

$$entropy = - \sum_{i=1}^{N_p} p(i) \log(X(i) + c)^2 \quad (2.3)$$

ϵ es un número positivo pequeño ($\approx 2.2 * 10^{-16}$)

Paso 1 . Registro de Imágenes



Crosshair Position

Origin

mm: -0.7 -12.9 1.3

vx: 256.7 257.7 133.3

Intensity: 621.243

right {mm}

0

forward {mm}

0

up {mm}

0

pitch {rad}

0

roll {rad}

0

yaw {rad}

0

resize {x}

1

resize {y}

1

resize {z}

1

Set Origin

Reorient...

File: .IAx_FSPGR_3D.nii

Dimensions: 512 x 512 x 272

Datatype: int16

Intensity: Y = 1 X

phase=?x;TE=1.844;time=20210115221104;

Vox size: -0.508 x 0.508 x 0.6

Origin: 254 283 138

Dir Cos: 0.996 -0.050 -0.070

0.068 0.953 0.295

0.052 -0.298 0.953

Full Volume

Show Crosshair

World Space

Trilinear interp.

Auto Window


Remove Overlay

Paso 2 . Segmentación del ROI: Paciente con Glioma




Universidad
Andrés Bello®


Paciente46 - Axial - slice: 78



Paciente46 - Coronal - slice: 94




Paciente46 - Sagittal - slice: 78




Paso 3 . Normalización intensidades


Paciente46
Normalized Z-score + Percentiles
Axial - slice: 78



Paciente46
Normalized Z-score + Percentiles
Coronal - slice: 94



Paciente46
Normalized Z-score + Percentiles
Sagittal - slice: 78




Normalización Z score: Imágenes que tengan una distribución similar de intensidades, ajusta a una distribución con media 0 y std 1.

Normalización por percentiles: Asegura que los valores que caen fuera del rango de percentiles (5 y 95) sean recortados y los valores dentro de ese rango se normalizan entre 0 y 1.

Para gliomas, combinación entre ambos enfoques ajusta intensidades extremas.

Conceptos de Diagnóstico Asistido

Tarea	Descripción	Ejemplo Clínico
Clasificación	Categorizar una lesión existente.	Benigno vs Maligno (PI-RADS AI).
Predicción	Anticipar un evento futuro.	Respuesta a la quimioterapia.
Detección (CAD)	Localizar el hallazgo.	Detección automática de aneurismas.



Diferenciación de Tejidos

La IA logra clasificar subtipos moleculares (ej: IDH mutado en gliomas) solo con la señal de RM, evitando biopsias invasivas.

Resultado: Menos falsos positivos y diagnósticos más certeros.

Evolución de la Detección Temprana



Universidad
Andrés Bello®

Lectura Humana Sola

72% Precisión

Humano + IA (CAD)

89% Precisión

Radiómica + Deep Learning

95% Precisión

La sinergia entre el ojo experto y el algoritmo minimiza el error diagnóstico.


- ¿Datos homogéneos y grupos de pacientes?
- ¿Lesiones u órganos segmentables?
- ¿Datos de resonancia magnética o tomografía computarizada u otros datos?
- ¿Existirá histopatología correlativa para cada caso incluido?
- ¿Existirán datos genómicos correlativos para cada caso?
- No necesariamente predicciones sobre el cáncer
- ¿Hay información compleja dentro de la imagen, qué exceda la evaluación humana?
- ¿Puede el proceso actual de toma de decisiones clínicas ser alternado por el hallazgo potencial?

- Control de Calidad: Identificar “alucinaciones” de la IA (artefactos creados por el algoritmo)
- Estandarización: La radiómica requiere que los protocolos sean idénticos entre pacientes
- Post-procesamiento: Ejecución y validación de mapas paramétricos automatizados

Pipeline




Universidad
Andrés Bello®



Aplicación: Predecir el grado de severidad tumoral en pacientes con gliomas




Universidad
Andrés Bello®



Aplicación: Predecir el grado de severidad tumoral en pacientes con gliomas






Universidad
Andrés Bello®



Las características seleccionadas por SFS, que minimizaron el error cuadrático medio (ECM) del modelo de radiofrecuencia ($0,0516 \pm 0,0374$), estaban compuestas por seis características.

Aplicación: Predecir el grado de severidad tumoral en pacientes con gliomas




Random Forest (5-fold nested CV):

$$\text{MSE} = 0.066 \pm 0.044$$

$$\text{MAE} = 0.182 \pm 0.069$$

$$R^2 = 0.307 \pm 0.432$$

Aplicación: Predecir el grado de severidad tumoral en pacientes con gliomas



Gráficos en cascada SHAP para pacientes con glioma de bajo grado, que ilustran la contribución de cada característica a la predicción final del modelo.

¡Ahora, vayamos a aprender en vivo!



 **Diplomado-MRI-UNAB** Public

 Pin  Watch 0  Fork 0  Star 0

 main  1 Branch  0 Tags

 Go to file  T  Add file  <> Code

 **pamelaFranco** Update codes cea6c8a · 1 hour ago  14 Commits

 Codes	Update codes	1 hour ago
 Dataset	Add Dataset	2 hours ago
 Figures	Update README	1 hour ago
 .gitignore	Primer commit: Estructura base del diplomado, códigos y R...	19 hours ago
 README.md	Add ML code	1 hour ago

 **README**  

Diplomado en Resonancia Magnética (MRI) - UNAB

About

Material práctico de Radiómica y Machine Learning para el Diplomado MRI UNAB

 Readme

 Activity

 0 stars

 0 watching

 0 forks

Releases

No releases published

[Create a new release](#)

Packages

No packages published

[Publish your first package](#)

<https://github.com/pamelaFranco/Diplomado-MRI-UNAB>

¡Ahora, vayamos a aprender en vivo!



Universidad
Andrés Bello®



