



Universidad
Andrés Bello®

Universidad Andrés Bello
Facultad de Ciencias de la Salud
Diplomado en Resonancia Magnética

Texto de Estudio Avanzado

Capítulo: La Ciencia de los Datos Radiómicos: Feature Selection, La Maldición de la Dimensionalidad y Arquitecturas Predictivas

Objetivo de este Material:

Este texto docente capacita al Tecnólogo Médico en el procesamiento avanzado de datos bioinformáticos derivados de la imagenología digital (RM, TC, PET). Se profundiza de forma rigurosa en el fenómeno matemático de la Maldición de la Dimensionalidad, la taxonomía y mecánica de la Selección de Características (*Feature Selection*), el uso clínico de la matriz de correlación, la lógica conceptual de los principales algoritmos de aprendizaje y la bifurcación de los *pipelines* de Clasificación y Regresión.

1. Introducción: El Vóxel como Biomarcador Digital

La **Radiómica** es el proceso de extracción masiva de características quantitative a partir de imágenes médicas, transformando la inspección visual cualitativa tradicional en un análisis de datos objetivo y reproducible. Esta metodología es **universal y agnóstica a la región anatómica o patología**: los algoritmos matemáticos procesan matrices n-dimensionales de vóxeles y mapas de grises sin importar si corresponden a tejido cerebral, hepático, prostático o mamario.

El reto fundamental de la radiómica no radica en extraer los datos, sino en procesarlos correctamente para evitar que el ruido estadístico de la imagen corrompa las predicciones clínicas del modelo, fundamentándose firmemente en los avances contemporáneos de la inteligencia artificial aplicada a la imagenología médica [1].

2. La Herramienta Estándar de la Industria: PyRadiomics

PyRadiomics es una plataforma de código abierto (*Harvard Medical School*) estandarizada bajo las normativas de la **IBSI (Image Biomarker Standardisation Initiative)**. Se distribuye en repositorios públicos de desarrollo y cuenta con un módulo gráfico oficial integrado en el software libre de visualización biomédica **3D Slicer**.

2.1. Flujo de Preprocesamiento en la Consola de Trabajo

1. **Corrección Geométrica de Orientación:** Los archivos médicos tridimensionales (como NIfTI) se indexan en matrices de almacenamiento $[Z, Y, X]$. Para evitar que el volumen se despliegue invertido en la interfaz del software, el Tecnólogo Médico supervisa la reorientación espacial para asegurar la conversión radiológica estándar (frente arriba, occipucio abajo, derecha anatómica a la izquierda del observador).
2. **Binning de Grises:** Las intensidades de la RM carecen de un valor físico absoluto. El *Binning* agrupa el espectro continuo de grises en compartimentos discretos de ancho fijo (`binWidth`). Este paso suprime el ruido electromagnético de fondo y viabiliza el cálculo matemático de las texturas.

3. La Matriz de Co-ocurrencia de Niveles de Gris (GLCM)

Las texturas de segundo orden evalúan la interacción espacial de los vóxeles dentro de una región de interés (ROI). La GLCM calcula la probabilidad conjunta $p(i, j)$ de que un vóxel de intensidad i se encuentre adyacente a un vóxel de intensidad j a una distancia δ y dirección θ .

3.1. Significado Matemático-Clínico de los Descriptores

- **Contraste (*Contrast*):** $\sum \sum (i - j)^2 p(i, j)$. El factor cuadratura magnifica los saltos bruscos de grises. Valores altos traducen una microarquitectura tisular caótica, heterogénea y agresiva.
- **Homogeneidad (*Id*):** $\sum \sum \frac{p(i, j)}{1 + |i - j|}$. Si los vecinos son idénticos, el denominador cae a 1, maximizando la ecuación. Mide la suavidad y monotonía del parénquima.
- **Energía Conjunta (*Joint Energy*):** $\sum \sum (p(i, j))^2$. Eleva las probabilidades al cuadrado. Si unas pocas combinaciones de gris dominan todo el tejido, la energía se aproxima a 1 (patrón predecible).
- **Entropía Conjunta (*Joint Entropy*):** $-\sum \sum p(i, j) \log_2 (p(i, j) + \epsilon)$. Basada en la teoría de Shannon, mide el caos puro. Alcanza su máximo cuando todas las combinaciones de color ocurren de forma aleatoria.

4. El Problema Central: La Maldición de la Dimensionalidad

Cuando el Tecnólogo Médico ejecuta PyRadiomics sobre una lesión, el software extrae de forma automatizada entre **1,200 y 1,800 características cuantitativas** (parámetros morfológicos, estadísticos, texturales y filtros Wavelet). Sin embargo, las cohortes de pacientes disponibles en un servicio hospitalario suelen ser limitadas (ej. 60 o 100 casos).

Matemáticamente, cuando el número de variables (D) supera con creces al número de muestras (N), el espacio euclidiano se expande exponencialmente y los datos se vuelven extremadamente dispersos. Esto se conoce como **La Maldición de la Dimensionalidad** y destruye los dos tipos de *pipelines* de formas específicas:

4.1. Impacto en el Pipeline de Clasificación

En clasificación (ej. Benigno vs. Maligno), el modelo busca trazar una frontera geométrica para separar los grupos. Al tener miles de dimensiones y pocos pacientes, los puntos de datos quedan completamente aislados en las esquinas del hiperespacio. El algoritmo encuentra fronteras de separación perfectas basadas puramente en el ruido o en artefactos de la imagen de esos pacientes específicos. El modelo sufre de **Sobreajuste (*Overfitting*)**: memoriza la muestra de entrenamiento con 100 % de precisión, pero al ingresar un paciente nuevo, el clasificador falla catastróficamente porque no aprendió un patrón biológico real, sino una coincidencia geométrica de la dispersión.

4.2. Impacto en el Pipeline de Regresión

En regresión (ej. predecir los meses de supervivencia o el índice molecular *Ki-67*), el modelo busca ajustar un hiperplano continuo que atraviese la nube de puntos. Con un exceso de dimensiones, existen infinitas combinaciones de pesos y coeficientes que pueden ajustarse perfectamente a la pequeña muestra de entrenamiento. El modelo de regresión se vuelve hiper-sensible: cualquier variación insignificante en el ruido de radiofrecuencia de la RM alterará drásticamente la pendiente del modelo, generando predicciones absurdas o inestables cuando se valida en un set de datos ciego.

5. La Solución: ¿Qué es Feature Selection y cómo se clasifica?

La **Selección de Características (Feature Selection)** es la disciplina de la ingeniería de datos que reduce el set original masivo extraído por PyRadiomics, aislando exclusivamente un subconjunto óptimo y compacto (típicamente de 5 a 15 variables) que contenga la mayor capacidad predictiva sin información redundante.

No debe confundirse con la reducción de dimensionalidad por extracción (como el PCA), ya que el *Feature Selection* **conserva el nombre y la identidad original de la variable**, permitiendo que el Tecnólogo Médico mantenga la interpretación clínica y física del biomarcador. Su taxonomía se divide en tres grandes familias:

5.1. 1. Métodos de Filtro (*Filter Methods*)

Son algoritmos estadísticos univariados que evalúan cada característica de forma aislada, ignorando por completo al modelo de Machine Learning. Funcionan como un tamiz inicial rápido y de bajo costo computacional.

- **Mecánica:** Calculan una métrica de asociación entre la variable y el desenlace clínico. Un ejemplo estándar es la **Prueba ANOVA (F-Value)**, la cual evalúa la razón de varianzas. Aquellas características con un Score F elevado demuestran que sus valores son drásticamente distantes entre las clases biológicas, pero muy estables y estrechos entre pacientes de la misma clase.
- **Ventaja/Desventaja:** Son ultra rápidos y evitan el sobreajuste, pero no detectan si dos variables están midiendo exactamente el mismo fenómeno (ignoran las interacciones).

5.2. 2. Métodos Envolventes (*Wrapper Methods*)

Utilizan un modelo de Machine Learning como una “caja negra” para evaluar la calidad de subconjuntos de variables de forma interactiva.

- **Mecánica:** El algoritmo selecciona un grupo de variables, entrena el modelo, mide su precisión y luego añade o remueve variables sistemáticamente. Un ejemplo es la **Eliminación Recíproca de Características (RFE)**, que entrena el modelo con todas las variables, evalúa la importancia de cada una a través de sus pesos, y va podando o eliminando las menos útiles en cada iteración hasta quedarse con el número deseado.
- **Ventaja/Desventaja:** Encuentran combinaciones de variables altamente sinérgicas y potentes, pero son computacionalmente costosos y propensos a indicar sobreajuste si la muestra es pequeña.

5.3. 3. Métodos Integrados o Incrustados (*Embedded Methods*)

Son algoritmos donde el proceso de selección de características ocurre de forma intrínseca y simultánea durante el propio entrenamiento del modelo.

- **Mecánica:** Utilizan penalizaciones matemáticas directas integradas en su función de pérdida. El ejemplo fundamental es la **Regresión LASSO (Regularización L1)**. LASSO añade una penalización proporcional al valor absoluto de los coeficientes del modelo. Durante el entrenamiento, fuerza activamente a los coeficientes de las variables redundantes o poco informativas a convertirse exactamente en **cero**, ejecutando una selección automática de variables.
- **Ventaja/Desventaja:** Combinan la eficiencia de los filtros con la inteligencia de los métodos envolventes, optimizando el rendimiento directo del clasificador o regresor.

5.4. La Herramienta de Diagnóstico Interno: La Matriz de Correlación

Incluso tras aplicar un filtro como ANOVA, el pipeline puede retener variables redundantes (ej. tres tipos de entropías que miden esencialmente el mismo caos tisular). La

Matriz de Correlación utiliza el coeficiente de Pearson (r), acotado entre -1 y 1 , para evaluar la relación lineal entre pares de variables.

Si el mapa de calor revela una colinealidad crítica ($|r| > 0,85$), el Tecnólogo Médico aplica un criterio de exclusión manual o automatizado: se descarta una de las dos variables redundantes, reteniendo aquella que posea la mayor estabilidad técnica ante el ruido o el mayor sentido físico-biológico, protegiendo al modelo de la sobre-parametrización.

6. Comprensión Conceptual de los Algoritmos de Aprendizaje

Para interactuar eficazmente con un entorno de radiómica computacional, el profesional clínico debe comprender cómo razonan internamente las herramientas predictivas más comunes:

6.1. 1. Random Forest (Bosques Aleatorios): La Junta Médica

En lugar de depender de los sesgos o criterios de un único clasificador lineal, este algoritmo crea un “ensamble” compuesto por cientos de árboles de decisión independientes. Durante el entrenamiento, a cada árbol se le muestra solo un subconjunto aleatorio de pacientes y de variables texturales para evitar la memorización. Ante un nuevo paciente, cada árbol realiza un descarte lógico y emite un diagnóstico individual. El modelo final tabula las respuestas y determina el diagnóstico por ****votación de mayoría****. Clínicamente es altamente robusto frente a imágenes con artefactos, ya que el error de un árbol es compensado por el consenso de la junta.

6.2. 2. K-Nearest Neighbors (KNN / K-Vecinos más Cercanos): Analogía Geométrica

Este algoritmo opera bajo la premisa asistencial clásica: *“Esta lesión se comporta igual a los casos similares que se procesaron previamente”*. KNN mapea al paciente dentro de un espacio geométrico multidimensional donde los ejes corresponden a las texturas seleccionadas (ej. Contraste vs. Homogeneidad). Al ingresar una muestra incógnita, busca las ****K muestras más cercanas**** en distancia euclidiana dentro de la base de datos histórica. Si $K = 5$, y cuatro de las imágenes vecinas corresponden analíticamente a tejido sano y una a tejido patológico, el sistema asigna el diagnóstico de tejido sano. Su gran sensibilidad radica en que cualquier ruido electromagnético severo desplazará la coordenada de posición, induciendo clasificaciones erróneas.

6.3. 3. Redes Neuronales Artificiales (ANN): Jerarquización Bio-Inspirada

Diseñadas de manera homóloga a la corteza visual, constan de unidades matemáticas interconectadas (neuronas) dispuestas en capas consecutivas. La ****Capa de Entrada**** recibe las métricas crudas de PyRadiomics; las ****Capas Ocultas**** procesan la información de manera abstracta (las primeras capas identifican bordes, discontinuidades o gradientes locales sencillos de gris, mientras que las profundas asocian esos elementos en arquitecturas texturales macro complejas); finalmente, la ****Capa de Salida**** proyecta la probabilidad

de la patología. El aprendizaje ocurre ajustando iterativamente la fuerza de las conexiones matemáticas mediante retropropagación (*backpropagation*) al detectar errores de calibración diagnóstica en el entrenamiento.

7. Divergencia de Arquitecturas y Modelado Clínico

Una vez purificado el set de datos mediante *Feature Selection*, el flujo se bifurca según la naturaleza matemática del objetivo clínico fijado.

7.1. Pipeline de Clasificación (Variables Discretas)

Se ejecuta para predecir etiquetas nominales o categorías cerradas (ej. Mutado vs. No mutado, Presencia vs. Ausencia de fibrosis).

- **Regresión Logística:** Emplea la combinación lineal de pesos y variables para alimentar a la **Función Sigmoide**:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

Comprime cualquier entrada real en un rango de 0 a 1, interpretado como la probabilidad exacta de pertenecer a la clase de sospecha.

- **Random Forest (Bosques Aleatorios):** Descrito en la sección previa; actúa votando sobre las categorías diagnósticas discretas.

7.2. Pipeline de Regresión (Variables Continuas)

Se ejecuta para estimar una métrica numérica real o un parámetro cuantitativo en una escala infinita (ej. meses de supervivencia, porcentaje de carga tumoral).

- **Regresión Lineal Múltiple:** Modela la relación trazando un hiperplano que cruza la nube de puntos continuos, minimizando la distancia vertical de los errores:

$$Y_{predicho} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n \quad (2)$$

- **Regresión Ridge/LASSO:** Variantes lineales que incorporan penalizaciones para restringir la magnitud de los coeficientes β , evitando que el modelo de regresión se vuelva inestable ante pequeñas fluctuaciones de la intensidad en la RM.

8. Validación Clínica y Métricas de Rendimiento

La cohorte se fragmenta herméticamente en un ****Set de Entrenamiento (70 %)**** y un ****Set de Prueba Ciego (30 %)****. La evaluación final se rige bajo lógicas completamente distintas:

8.1. Métricas para Clasificación (Matriz de Confusión)

- **Sensibilidad (*Recall*)** = $\frac{TP}{TP+FN}$: Proporción de enfermos reales que el software detectó. Un valor bajo genera Falsos Negativos (Errores Tipo II), privando al paciente de terapia inmediata.
- **Precisión (*Precision*)** = $\frac{TP}{TP+FP}$: Probabilidad de que un paciente etiquetado como positivo realmente tenga la condición, previniendo Falsos Positivos (Errores Tipo I).
- **F1-Score**: Media armónica que penaliza desequilibrios extremos entre las dos métricas anteriores.

8.2. Métricas para Regresión (Magnitud del Desfase)

Al no existir categorías, se mide qué tan lejos está la predicción continua del valor real.

- **Error Absoluto Medio (MAE)**: Promedio directo del desfase numérico en las unidades reales estudiadas (ej. error por $\pm 4,2$ meses de supervivencia).

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (3)$$

- **Error Cuadrático Medio (MSE)**: Eleva las diferencias al cuadrado antes de promediarlas, penalizando de forma severa al modelo si comete desviaciones gigantescas en pacientes aislados.

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \quad (4)$$

- **Coefficiente de Determinación (R^2)**: Proporción de la varianza real del parámetro clínico que el modelo radiómico logra explicar. Varía entre 0 y 1; un $R^2 = 0,82$ significa que las texturas de la imagen explican exitosamente el 82 % del comportamiento real del tejido.

Referencias

- [1] D. Mery, C. Pieringer (Eds.), *Computer Vision for X-Ray Testing*, Springer, Cham, 2021.
<https://link.springer.com/book/10.1007/978-3-030-56769-9>
- [2] R. Li, L. Xing, S. Napel, DL. Rubin (Eds.), *Radiomics and Radiogenomics: Technical Basis and Clinical Applications*, CRC Press, 2019.
<https://www.routledge.com/Radiomics-and-Radiogenomics-Technical-Basis-and-Clinical-Li-Xing-Napel-Rubin/p/book/9780367779580>
- [3] G. James, D. Witten, T. Hastie, y R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R and Python*, Springer, 2a Edición, 2021.
<https://link.springer.com/book/10.1007/978-1-0716-1418-1>